

確率統計 クラス<5>

第2回

確率分布と平均・分散

担当：小林 光木

Version 2.0.0 最終更新：2026 年 10 月 6 日



1. 確率変数

2. 確率分布と分布関数

3. 離散型確率分布

4. 連続型確率分布

5. 平均・期待値

6. 分散と標準偏差

7. 積率・積率母関数・特性関数

8. データの特徴を表す量

標本点にラベルを付ける


例

赤玉 3 個、青玉 2 個入った袋から玉を 1 個取り出す試行を考える。
標本空間 $\Omega = \{\omega_1, \dots, \omega_5\}$ でこの 5 個の玉を標本点として表現する。このとき、

$$A := \{\omega \mid \omega \text{ は赤玉} \}, \quad A^c = \{\omega \mid \omega \text{ は青玉} \}$$

とにおいて、算術的確率を考えれば

$$P(A) = \frac{\#A}{\#\Omega} = \frac{3}{5}, \quad P(A^c) = \frac{\#A^c}{\#\Omega} = \frac{2}{5}$$



確率変数

標本点に価値を付ける

- 確率的な試行において自分が得たものには、しばしば点数や金銭的な価値などが付けられていることがある。
- 同じ試行を繰り返す中で、何をいくつ得たのか、その数自体が意味を持つこともある。

定義 (確率変数)

$(\Omega, \mathcal{F}, P)$ を確率空間とする。確率変数 X とは、

$$\text{標本点} : \omega \mapsto \text{実数} : X(\omega)$$

と対応させた、次を満たす Ω 上の実数値関数 $X : \Omega \rightarrow \mathbb{R}$ のことをいう：

$$\{\omega \mid X(\omega) \leq a\} \in \mathcal{F} \quad (\forall a \in \mathbb{R})$$

なお、以降は確率空間を暗黙の内に取るものとする。

確率変数

記法

簡単のため、この講義では以下のように略記する：

$$\{X \leq a\} := \{\omega \mid X(\omega) \leq a\}$$

命題

a, b を任意の実数とする。確率変数 X に関して、次が成り立つ：

- (1) $\{X = a\}, \{X \leq a\}, \{X < a\}, \{X > a\}, \{X \geq a\} \in \mathcal{F}$
- (2) $\{a < X < b\}, \{a \leq X < b\}, \{a < X \leq b\}, \{a \leq X \leq b\} \in \mathcal{F}$

補足

$\{X < a\}$ の証明が少し手間だが、確率の定義や写像の性質から直ちに従う。
証明はここでは割愛し、確率論に譲る。

例 (ベルヌーイ試行)


記法

確率変数は基本的に大文字 $X, Y, Z, \dots$ などで表す。

例 (ベルヌーイ試行)

事象 A に対して、確率変数 X を次で定める：

$$X(\omega) := \begin{cases} 1 & (\omega \in A), \\ 0 & (\omega \notin A) \end{cases}$$



1. 確率変数

2. 確率分布と分布関数

3. 離散型確率分布

4. 連続型確率分布

5. 平均・期待値

6. 分散と標準偏差

7. 積率・積率母関数・特性関数

8. データの特徴を表す量

確率分布と分布関数

記法

簡単のため、この講義では以下のように略記する：

$$P(X \leq a) := P(\{X \leq a\}) = P(\{\omega \mid X(\omega) \leq a\})$$

定義 (確率分布)

X を確率変数とする。次で定まる $\mathbb{R}$ 上の確率 P_X を X の**確率分布**という：

$$P_X((-\infty, a]) = P(X \leq a) \quad (\forall a \in \mathbb{R})$$

P_X を X の**分布**とも言う。また、次で定まる関数 F_X を X の**分布関数**という：

$$F_X(x) = P(X \leq x) \quad (x \in \mathbb{R})$$

注意

確率分布 P_X と分布関数 F_X は定義域が異なり、別物なので注意。

例 (ベルヌーイ試行)



例 (ベルヌーイ試行)

事象 A に対して、確率変数 X を次で定める：

$$X(\omega) := \begin{cases} 1 & (\omega \in A), \\ 0 & (\omega \notin A) \end{cases}$$

$p := P(A)$ と置くと、 $F_X(x) = P(X \leq x)$ に注意して、

$$\begin{cases} P_X(\{1\}) = P(X=1) = p, \\ P_X(\{0\}) = P(X=0) = 1-p, \end{cases} \quad F_X(x) = \begin{cases} 1 & (x \geq 1), \\ 1-p & (0 \leq x < 1), \\ 0 & (x < 0) \end{cases}$$



分布関数の性質

定義

確率変数 X, Y の分布が等しいとは、次の2つの同値な条件を満たすこと：

- (1) X, Y の確率分布が等しい。 (2) X, Y の分布関数が等しい。

命題 (分布関数の性質)

確率変数 X の分布関数 $F_X(x) = P(X \leq x)$ は次を満たす：

- (1) 全ての $x \in \mathbb{R}$ について $0 \leq F_X(x) \leq 1$
(2) $x \leq y$ ならば $F_X(x) \leq F_X(y)$
(3) $\lim_{x \rightarrow -\infty} F_X(x) = 0$ 、 $\lim_{x \rightarrow \infty} F_X(x) = 1$
(4) F_X は右連続である：

$$F_X(x) = F_X(x+) := \lim_{h \rightarrow +0} F_X(x+h)$$

1. 確率変数

2. 確率分布と分布関数

3. 離散型確率分布

4. 連続型確率分布

5. 平均・期待値

6. 分散と標準偏差

7. 積率・積率母関数・特性関数

8. データの特徴を表す量

離散型分布の定義

定義 (離散型確率変数・離散型確率分布・確率関数)

確率変数 X が**離散値**の場合、すなわち $x_k \in \mathbb{R}$ に対して、

$$x_1, \dots, x_n, \quad \text{や} \quad x_1, x_2, \dots$$

のような高々可算個の値しか取り得ないとき、 X を**離散型確率変数**と呼ぶ。
このとき、 X の確率分布を**離散型確率分布** (あるいは単に**離散分布**) と呼ぶ。
また、

$$p_X(x_k) := P(X = x_k), \quad k = 1, 2, \dots$$

で定まる関数 $p_X : \{x_1, x_2, \dots\} \rightarrow [0, 1]$ を X の**確率関数**という。


確率関数と分布関数

命題


離散型確率変数 X の取り得る値を $x_1, x_2, \dots$ とする。

このとき、 X の分布関数 $F_X(x)$ と確率関数 $p_X(x)$ に関して次が成立：

$$(1) \quad 0 \leq p_X(x_k) \leq 1, \sum_k p_X(x_k) = 1 \quad (2) \quad F_X(x) = \sum_{k: x_k \leq x} p_X(x_k)$$



確率関数 p_X



分布関数 F_X

確率分布表

確率分布表

離散型確率変数 X の取り得る値とその確率を対応させた次のような表

x	x_1	x_2	x_3	$\cdots$	合計
$P(X = x)$	p_1	p_2	p_3	$\cdots$	1

を**確率分布表**という。ただし、 $p_k := p_X(x_k) = P(X = x_k)$ とおいた。

例

x	x_1	x_2	x_3	x_4
$P(X = x)$	0.2	0.3	0.1	0.4

(合計の列はない場合もある)

注意

確率分布表を与えることと離散分布を与えることは互いに同値。

離散型における確率計算


命題

離散型確率変数 X と実数 $a \leq b$ に対して、


$$P(a \leq X \leq b) = \sum_{k: a \leq x_k \leq b} p_k.$$

特に X が整数値を取り、 a, b が整数なら、

$$P(a \leq X \leq b) = \sum_{k=a}^b P(X = k).$$



一般の離散値の場合



整数値の場合

例 (確率分布表)

例

離散型確率変数 X の確率分布表が次で与えられるとする：

x	-2	0	3	7
$P(X = x)$	$\frac{1}{8}$	$\frac{3}{8}$	$\frac{1}{4}$	$\frac{1}{4}$

(1) $p_X(7)$ は

$$p_X(7) = \frac{1}{4}.$$

(2) $P(-1 \leq X \leq 4)$ は

$$P(-1 \leq X \leq 4) = P(X = 0) + P(X = 3) = \frac{3}{8} + \frac{1}{4} = \frac{5}{8}.$$

(3) $F_X(2)$ は

$$F_X(2) = P(X \leq 2) = P(X = -2) + P(X = 0) = \frac{1}{2}.$$

例 (可算無限)

例

公平なコインを繰り返し投げ、初めて表が出るまでに投げた回数を X とする。

(1) $X = k$ となるのは、最初の $k - 1$ 回が裏で、第 k 回に表が出るときだから

$$P(X = k) = \left(\frac{1}{2}\right)^{k-1} \left(\frac{1}{2}\right) = \frac{1}{2^k}, \quad k = 1, 2, 3, \dots$$

(2) $2 \leq X \leq 4$ となる確率は

$$P(2 \leq X \leq 4) = \sum_{k=2}^4 P(X = k) = \sum_{k=2}^4 \frac{1}{2^k} = \frac{1}{4} + \frac{1}{8} + \frac{1}{16} = \frac{7}{16}.$$

(3) $X \geq 4$ となる確率は

$$P(X \geq 4) = \sum_{k=4}^{\infty} P(X = k) = \sum_{k=4}^{\infty} 2^{-k} = \frac{1}{8}.$$

あるいは $P(X \geq 4) = 1 - P(X \leq 3)$ を計算しても良い。

1. 確率変数

2. 確率分布と分布関数

3. 離散型確率分布

4. 連続型確率分布

5. 平均・期待値

6. 分散と標準偏差

7. 積率・積率母関数・特性関数

8. データの特徴を表す量


連続型確率分布

定義 (連続型)


確率変数 X に対して、ある関数 $f_X : \mathbb{R} \rightarrow [0, \infty)$ が存在して、

$$F_X(x) = P(X \leq x) = \int_{-\infty}^x f_X(t) dt \quad (\forall x \in \mathbb{R})$$

と表せるとき、 X を連続型確率変数と呼び、 X の分布を連続型確率分布と呼ぶ。
また、関数 f_X を X の確率密度関数という。



確率密度関数 f_X



分布関数 F_X

密度関数と分布関数


命題

連続型確率変数 X の確率密度関数 f_X について、次が成り立つ：


$$(1) \quad f_X(x) \geq 0 \qquad (2) \quad \int_{\mathbb{R}} f_X(x) dx = 1 \qquad (3) \quad P(X = x) = 0$$

また、 f_X が $x = x_0$ で連続なら、

$$F'_X(x_0) = f_X(x_0).$$



確率密度関数 f_X




分布関数 F_X

連続な分布

発展 (確率論)

連続な分布関数が、必ず確率密度関数を持つとは限らない。
実際、分布関数が連続で確率密度関数を持たない分布として、Cantor 分布があり、**特異連続**な分布の代表例として知られている (下図参照)。
一方、確率密度を持つような分布は**絶対連続**な分布と言う。



Cantor 関数の近似図

Cantor 関数の性質：


- 連続
- 単調非減少
- $F(0) = 0, F(1) = 1$
- ほとんど至る所で $F'(x) = 0$
- 確率密度関数を持たない。

連続型の確率計算


命題

連続型確率変数 X と実数 $a \leq b$ に対して、

$$P(a \leq X \leq b) = \int_a^b f_X(x) dx = F_X(b) - F_X(a).$$



確率密度関数 f_X



分布関数 F_X

連続型の例

例

確率変数 X の確率密度関数を次で与える：

$$f_X(x) = \begin{cases} 6x(1-x), & 0 \leq x \leq 1, \\ 0, & \text{それ以外} \end{cases}$$

(1) $\frac{1}{4} \leq X \leq \frac{3}{4}$ となる確率は

$$P\left(\frac{1}{4} \leq X \leq \frac{3}{4}\right) = \int_{1/4}^{3/4} 6x(1-x) dx = [3x^2 - 2x^3]_{1/4}^{3/4} = \frac{11}{16}.$$

(2) $F_X(x) = P(X \leq x)$ は

$$F_X(x) = \begin{cases} 0, & x < 0, \\ 3x^2 - 2x^3, & 0 \leq x \leq 1, \\ 1, & x > 1. \end{cases}$$

(3) 分布関数を使えば $P\left(\frac{1}{4} \leq X \leq \frac{3}{4}\right) = F_X\left(\frac{3}{4}\right) - F_X\left(\frac{1}{4}\right) = \frac{11}{16}.$

1. 確率変数

2. 確率分布と分布関数

3. 離散型確率分布

4. 連続型確率分布

5. 平均・期待値

6. 分散と標準偏差

7. 積率・積率母関数・特性関数

8. データの特徴を表す量

データの平均

定義 (データの平均)

確率変数 X を観測して得られた n 個のデータを

$$x_1, x_2, \dots, x_n$$

とする。このとき、次をこのデータの**平均**という：

$$\bar{x} = \frac{1}{n} \sum_{k=1}^n x_k$$

データから確率変数へ

- データの平均は各データ x_k に同じ重み $1/n$ を付けた**重み付き平均**とみなせる。
- 確率変数 X の分布がわかっていたり、確率モデルとして表されている場合はどうだろうか？

離散型確率変数の平均

各標本点に報酬を定め、期待値を考える

離散的な標本空間 $\Omega = \{\omega_1, \omega_2, \dots\}$ の各標本点において、

$$\omega_k \mapsto X(\omega_k)$$

のように値 X を定め、各標本点の確率で重み付けして平均すると、

$$\sum_k X(\omega_k) P(\{\omega_k\})$$

X が取り得る値を $x_1, x_2, \dots$ とすると、同じ値をとる標本点をまとめることで

$$\sum_k X(\omega_k) P(\{\omega_k\}) = \sum_j x_j P(X = x_j) = \sum_j x_j p_j$$

定義 (平均・期待値)

離散型確率変数 X において、次で定まる値を X の平均、または期待値という：

$$E[X] := \sum_j x_j p_j \quad \left(\text{ただし } \sum_j |x_j| p_j < \infty \right)$$

離散型確率変数の平均

例

(1) 次の確率分布表から期待値を計算することを考える。

x	-2	0	3	7
$P(X = x)$	$\frac{1}{8}$	$\frac{3}{8}$	$\frac{1}{4}$	$\frac{1}{4}$

$$E[X] = (-2) \cdot \frac{1}{8} + 0 \cdot \frac{3}{8} + 3 \cdot \frac{1}{4} + 7 \cdot \frac{1}{4} = \frac{9}{4}.$$

(2) 公平なコインを繰り返し投げ、初めて表が出るまでの回数を X とする。

$$P(X = k) = \frac{1}{2^k}, \quad k = 1, 2, 3, \dots$$

$$\sum_{k=1}^{\infty} k r^{k-1} = 1/(1-r)^2 \quad (|r| < 1) \text{ より}$$

$$E[X] = \sum_{k=1}^{\infty} k \frac{1}{2^k} = \frac{1}{2} \sum_{k=1}^{\infty} k \left(\frac{1}{2}\right)^{k-1} = \frac{1}{2} \frac{1}{(1-1/2)^2} = 2.$$

連続型確率変数の平均

定義 (平均・期待値)

連続型確率変数 X の確率密度関数を f_X とするとき、

$$E[X] := \int_{-\infty}^{\infty} x f_X(x) dx \quad \left(\text{ただし } \int_{-\infty}^{\infty} |x| f_X(x) dx < \infty \right)$$

を X の平均、または期待値という。

例

確率密度関数

$$f_X(x) = \begin{cases} 6x(1-x), & 0 \leq x \leq 1, \\ 0, & \text{それ以外} \end{cases}$$

をもつ確率変数 X を考える。このとき

$$E[X] = \int_0^1 x 6x(1-x) dx = \int_0^1 (6x^2 - 6x^3) dx = \left[2x^3 - \frac{3}{2}x^4 \right]_0^1 = \frac{1}{2}.$$

$Y = g(X)$ の平均

命題

$Y = g(X)$ の平均は、 Y 自身の分布を求めなくても X の分布から計算できる。

離散型: $E[g(X)] = \sum_k g(x_k) p_k$ (ただし $\sum_k |g(x_k)| p_k < \infty$)

連続型: $E[g(X)] = \int_{-\infty}^{\infty} g(x) f_X(x) dx$. (ただし $\int_{-\infty}^{\infty} |g(x)| f_X(x) dx < \infty$)

離散型の場合.

$Y = g(X)$ の取り得る値を $y_1, y_2, \dots$ とすると、

$$\begin{aligned} E[g(X)] &= \sum_j y_j P(Y = y_j) \\ &= \sum_j y_j \sum_{k: g(x_k)=y_j} p_k = \sum_k g(x_k) p_k. \end{aligned}$$

$Y = g(X)$ の平均

連続型の場合.

簡単のため、密度は連続で、 g は微分可能かつ $g'(x) > 0$ とする。

$$Y = g(X), \quad y = g(x), \quad \Delta y = g(x + \Delta x) - g(x).$$

g は狭義単調増加なので、

$$x < X \leq x + \Delta x \iff y < Y \leq y + \Delta y.$$

$$f_X(x)\Delta x \approx P(x < X \leq x + \Delta x) = P(y < Y \leq y + \Delta y) \approx f_Y(y)\Delta y.$$

微小区間で考えれば $f_X(x) dx = f_Y(y) dy$. だから、 $y = g(x)$ より、

$$E[g(X)] = E[Y] = \int_{-\infty}^{\infty} y f_Y(y) dy = \int_{-\infty}^{\infty} g(x) f_X(x) dx.$$

補足

一般の g に対しても同じ公式が成り立つが、証明は確率論に譲る。

1. 確率変数

2. 確率分布と分布関数

3. 離散型確率分布

4. 連続型確率分布

5. 平均・期待値

6. 分散と標準偏差

7. 積率・積率母関数・特性関数

8. データの特徴を表す量

分散と標準偏差

定義 (分散と標準偏差)

$E[X^2] < \infty$ を満たす確率変数 X に対して、

$$V[X] := E[(X - E[X])^2]$$

を X の**分散**といい、

$$\sigma_X := \sqrt{V[X]}$$

を X の**標準偏差**という。

離散型・連続型の分散

離散型 $V[X] = \sum_k (x_k - E[X])^2 p_k.$

連続型 $V[X] = \int_{-\infty}^{\infty} (x - E[X])^2 f_X(x) dx.$

平均と分散の性質

命題

a, b を定数とする。

$$(1) \ E[|X|] < \infty \text{ なら、 } E[aX + b] = aE[X] + b$$

$$(2) \ E[X^2] < \infty \text{ なら、 } V[aX + b] = a^2 V[X]$$

離散型・連続型の証明.

(1) $g(x) = ax + b$ とおくと、前節の $E[g(X)]$ の公式より

$$E[aX + b] = aE[X] + b$$

(2) (1) より

$$\begin{aligned} V[aX + b] &= E[(aX + b - E[aX + b])^2] = E[(aX - aE[X])^2] \\ &= a^2 E[(X - E[X])^2] = a^2 V[X] \end{aligned}$$

分散公式

命題 (分散公式)

$E[X^2] < \infty$ ならば

$$V[X] = E[X^2] - (E[X])^2.$$

証明.

$m = E[X]$ とおくと

$$\begin{aligned} V[X] &= E[(X - m)^2] = E[X^2 - 2mX + m^2] \\ &= E[X^2] - 2mE[X] + m^2 = E[X^2] - m^2 \end{aligned}$$

発展 (確率論)

前ページの命題と分散公式は、離散型・連続型に関して示した。
いずれも一般の X に対して成り立つが、詳しい証明は確率論に譲る。

例 (離散型・有限)

例

(1) 確率分布表

x	-2	0	3	7
$P(X = x)$	$\frac{1}{8}$	$\frac{3}{8}$	$\frac{1}{4}$	$\frac{1}{4}$

において、 $E[X] = \frac{9}{4}$ より

$$E[X^2] = (-2)^2 \cdot \frac{1}{8} + 0^2 \cdot \frac{3}{8} + 3^2 \cdot \frac{1}{4} + 7^2 \cdot \frac{1}{4} = 15.$$

$$V[X] = E[X^2] - E[X]^2 = 15 - \left(\frac{9}{4}\right)^2 = \frac{159}{16},$$

$$\sigma_X = \sqrt{V[X]} = \frac{\sqrt{159}}{4}.$$

例 (離散型・可算無限)

例

公平なコインを繰り返し投げ、初めて表が出るまでの回数を X とする。前に求めたように、

$$P(X = k) = \frac{1}{2^k}, \quad k = 1, 2, 3, \dots, \quad E[X] = 2.$$

$$\sum_{k=1}^{\infty} k^2 r^{k-1} = \frac{d}{dr} \left(\frac{r}{(1-r)^2} \right) = \frac{1+r}{(1-r)^3} \quad (|r| < 1)$$

より、

$$E[X^2] = \sum_{k=1}^{\infty} k^2 \frac{1}{2^k} = \frac{1}{2} \frac{1 + 1/2}{(1 - 1/2)^3} = 6,$$

$$V[X] = E[X^2] - E[X]^2 = 6 - 2^2 = 2, \quad \sqrt{V[X]} = \sqrt{2}.$$

例 (連続型)

例

確率密度関数が

$$f_X(x) = \begin{cases} 6x(1-x), & 0 \leq x \leq 1, \\ 0, & \text{それ以外} \end{cases},$$

のとき、 $E[X] = \frac{1}{2}$ より

$$E[X^2] = \int_0^1 x^2 6x(1-x) dx = \int_0^1 (6x^3 - 6x^4) dx = \frac{3}{10}.$$

したがって、

$$V[X] = E[X^2] - E[X]^2 = \frac{3}{10} - \frac{1}{4} = \frac{1}{20},$$

$$\sigma_X = \sqrt{V[X]} = \frac{1}{2\sqrt{5}}.$$

標準化

定義 (標準化)

$E[X^2] < \infty$ かつ $V[X] > 0$ を満たす確率変数 X に対して、

$$Z = \frac{X - E[X]}{\sqrt{V[X]}}$$

を X の標準化という。特に、平均 m 、標準偏差 σ とすると、 $Z = \frac{X-m}{\sigma}$ 。

命題

$E[X^2] < \infty$, $V[X] > 0$ を満たす確率変数 X の標準化 Z に関して、次が成立：

$$E[Z] = 0, \quad V[Z] = 1$$

補足

標準化により単位が無次元化されるので、異なる尺度の量を比較しやすくなる。

1. 確率変数

2. 確率分布と分布関数

3. 離散型確率分布

4. 連続型確率分布

5. 平均・期待値

6. 分散と標準偏差

7. 積率・積率母関数・特性関数

8. データの特徴を表す量

積率・中心積率・標準化積率

定義 (積率・中心積率・標準化積率)

n を正整数、確率変数 X の平均を m 、 $E[|X|^n] < \infty$ とし、次を定める：

- n 次積率 (n 次モーメント)

$$E[X^n]$$

- n 次中心積率 (n 次中心モーメント)

$$E[(X - m)^n]$$

さらに、標準偏差 $\sigma > 0$ を持つとき、次を定める：

- n 次標準化積率 (n 次標準化モーメント)

$$E\left[\left(\frac{X - m}{\sigma}\right)^n\right]$$

- 3 次標準化積率を**歪度**という。分布の左右の非対称性を表す一つの尺度。
- 4 次標準化積率 β を**尖度**、 $\beta - 3$ を**超過尖度**と呼ぶ。正規分布では $\beta = 3$ 。

積率母関数と特性関数

定義 (積率母関数・特性関数)

確率変数 X に対して、

$$M_X(t) := E[e^{tX}]$$

が $t = 0$ を含むある開区間上で有限となるとき、 M_X を X の積率母関数といい、

$$\varphi_X(t) := E[e^{itX}]$$

で定まる関数 φ_X を X の特性関数という。ここで、 i は虚数単位である。

離散型・連続型における積率母関数・特性関数

$$\text{離散型: } M_X(t) = \sum_k e^{tx_k} p_k, \quad \varphi_X(t) = \sum_k e^{itx_k} p_k,$$

$$\text{連続型: } M_X(t) = \int_{-\infty}^{\infty} e^{tx} f_X(x) dx, \quad \varphi_X(t) = \int_{-\infty}^{\infty} e^{itx} f_X(x) dx.$$

積率母関数・特性関数と確率分布

定理

確率変数 X, Y について、

(1) X と Y の分布が等しい: $P(X \leq a) = P(Y \leq a) \quad (\forall a \in \mathbb{R})$

(2) 特性関数が等しい: $\varphi_X(t) = \varphi_Y(t) \quad (\forall t \in \mathbb{R})$

は同値である。また、

0 を含むある开区間で積率母関数が等しい: $M_X(t) = M_Y(t)$

が成り立つなら、 X と Y の分布は等しい。

注意

特性関数は全ての $t \in \mathbb{R}$ で定義できるが、積率母関数は存在しないこともある。

積率と積率母関数の関係

命題 (積率母関数と積率)

積率母関数 M_X が存在するとき、次が成り立つ。

(1) M_X は $t = 0$ のまわりで次のように展開できる：

$$M_X(t) = \sum_{n=0}^{\infty} \frac{E[X^n]}{n!} t^n$$

(2) 任意の正整数 n について

$$M_X^{(n)}(0) = E[X^n].$$

特に、 $E[X] = M'_X(0)$ 、 $V[X] = M''_X(0) - (M'_X(0))^2$ が成り立つ。

証明の概略.

$$M_X(t) = E[e^{tX}] = E\left[\sum_{n=0}^{\infty} \frac{(tX)^n}{n!}\right] = \sum_{n=0}^{\infty} \frac{E[X^n]}{n!} t^n.$$

積率母関数の例（離散型）

例

公平なコインを繰り返し投げ、初めて表が出るまでに投げた回数を X とする。

$$P(X = k) = \frac{1}{2^k}, \quad k = 1, 2, 3, \dots$$

このとき、

$$\begin{aligned} M_X(t) &= E[e^{tX}] = \sum_{k=1}^{\infty} e^{tk} \frac{1}{2^k} \\ &= \sum_{k=1}^{\infty} \left(\frac{e^t}{2}\right)^k = \frac{e^t}{2 - e^t}, \quad t < \log 2. \end{aligned}$$

したがって、

$$M'_X(0) = 2, \quad M''_X(0) = 6,$$

より

$$E[X] = 2, \quad V[X] = 6 - 2^2 = 2.$$

積率母関数の例（連続型）

例

確率密度関数

$$f_X(x) = \begin{cases} e^{-x}, & x > 0, \\ 0, & x \leq 0 \end{cases}$$

をもつ確率変数 X を考える。

$$\begin{aligned} M_X(t) &= E[e^{tX}] = \int_0^{\infty} e^{tx} e^{-x} dx \\ &= \int_0^{\infty} e^{-(1-t)x} dx = \frac{1}{1-t}, \quad t < 1. \end{aligned}$$

したがって、

$$M'_X(t) = \frac{1}{(1-t)^2}, \quad M''_X(t) = \frac{2}{(1-t)^3}.$$

よって、

$$E[X] = M'_X(0) = 1, \quad V[X] = M''_X(0) - (M'_X(0))^2 = 1.$$

積率に関する注意

注意

- 全ての次数の積率が存在しても、積率母関数が存在するとは限らない。
- 確率変数 X, Y について

$$E[X^n] = E[Y^n] \quad (n = 1, 2, \dots)$$

が全て成り立っても、 X, Y の分布が等しいとは限らない。

このように、積率列から分布が一意に定まらない場合を**積率不定**という。

例 (全積率の存在 $\nRightarrow$ 積率母関数の存在)

確率変数 X が標準的な対数正規分布の密度

$$f_0(x) = \frac{1}{x\sqrt{2\pi}} \exp\left\{-\frac{(\log x)^2}{2}\right\}, \quad x > 0$$

を持つとすると、

$$E[X^n] = e^{n^2/2} < \infty \quad (n = 1, 2, \dots), \quad E[e^{tX}] = \infty \quad (t > 0).$$

積率に関する注意

例 (積率不定性)

標準的な対数正規分布の密度

$$f_0(x) = \frac{1}{x\sqrt{2\pi}} \exp \left\{ -\frac{(\log x)^2}{2} \right\}, \quad x > 0$$

に対して、 $|a| \leq 1$ とし、確率変数 X_a は

$$f_a(x) = f_0(x) \{1 + a \sin(2\pi \log x)\}$$

を確率密度関数として持つとする。このとき、

$$f_a \neq f_0 \quad (a \neq 0)$$

である。一方、任意の $n = 0, 1, 2, \dots$ について

$$E[X_a^n] = \int_0^\infty x^n f_a(x) dx = \int_0^\infty x^n f_0(x) dx = e^{n^2/2}.$$

したがって、異なる X_a の分布が全て同じ積率をもつ。

1. 確率変数

2. 確率分布と分布関数

3. 離散型確率分布

4. 連続型確率分布

5. 平均・期待値

6. 分散と標準偏差

7. 積率・積率母関数・特性関数

8. データの特徴を表す量

確率変数の平均とデータの平均

確率変数の平均

$$E[X] = \sum_j x_j p_j$$

確率分布に対して定まり、各値をその**確率**で重み付けする。

データの平均

$$\bar{x} = \frac{1}{n} \sum_{k=1}^n x_k$$

観測されたデータに対して定まり、各データを同じ重み $1/n$ で平均する。

ポイント

どちらも重み付き平均という共通した形をもつが、 $E[X]$ と $\bar{x}$ は異なる量である。

データの分散と標準偏差

定義 (データの分散と標準偏差)

観測されたデータ $x_1, \dots, x_n$ の平均を $\bar{x}$ とする。

$$s^2 = \frac{1}{n} \sum_{k=1}^n (x_k - \bar{x})^2$$

をデータの**分散**といい、

$$s = \sqrt{s^2}$$

をデータの**標準偏差**という。

ポイント

$\bar{x}$ 、 s^2 、 s は、観測済みのデータから計算される数値である。

不偏分散

定義 (不偏分散)

観測されたデータ $x_1, \dots, x_n$ の平均を $\bar{x}$ とする。

$$u^2 = \frac{1}{n-1} \sum_{k=1}^n (x_k - \bar{x})^2$$

を不偏分散という。

データの分散との関係

データの分散

$$s^2 = \frac{1}{n} \sum_{k=1}^n (x_k - \bar{x})^2$$

との間には、

$$u^2 = \frac{n}{n-1} s^2$$

の関係がある。

データの標準化

定義 (データの標準化)

観測されたデータ $x_1, \dots, x_n$ の平均を $\bar{x}$ 、標準偏差を $s > 0$ とする。各データ x_k に対して、

$$z_k = \frac{x_k - \bar{x}}{s}, \quad k = 1, \dots, n$$

と変換することをデータの**標準化**という。

命題

標準化後のデータ $z_1, \dots, z_n$ について、

$$\frac{1}{n} \sum_{k=1}^n z_k = 0, \quad \frac{1}{n} \sum_{k=1}^n z_k^2 = 1.$$

ポイント

確率変数 X の標準化と同じ考え方を、観測済みのデータに適用している。

偏差値

定義 (偏差値)

観測されたデータ $x_1, \dots, x_n$ の平均を $\bar{x}$ 、標準偏差を $s > 0$ とする。各データ x_k の標準化

$$z_k = \frac{x_k - \bar{x}}{s}$$

に対して、

$$T_k = 50 + 10z_k = 50 + 10 \frac{x_k - \bar{x}}{s}$$

を x_k の偏差値という。

命題

偏差値 $T_1, \dots, T_n$ の平均と標準偏差は

$$\frac{1}{n} \sum_{k=1}^n T_k = 50, \quad \sqrt{\frac{1}{n} \sum_{k=1}^n (T_k - 50)^2} = 10.$$

偏差値の解釈

偏差値 60 の意味

偏差値

$$T = 50 + 10z$$

に対して、

$$T = 60 \iff z = 1.$$

したがって、偏差値 60 は平均より標準偏差 1 個分だけ上の位置を表す。この解釈には正規分布の仮定は必要ない。

上位何%かを解釈するには

データの分布が正規分布に近いとみなせるなら、標準化後は標準正規分布に近いので、

$$P(Z \geq 1) \approx 0.1587.$$

したがって、

$$\text{偏差値 60} \implies \text{上位約 15.9\%}.$$

度数分布表

定義 (階級・度数・度数分布表)

データの値をいくつかの区間に分けた各区間を**階級**、各階級に含まれるデータの個数を**度数**という。

階級と度数を対応させた表を**度数分布表**という。

例

階級	度数
10 以上 20 未満	2
20 以上 30 未満	4
30 以上 40 未満	3
40 以上 50 未満	1

ポイント

多数のデータは、値の範囲ごとにまとめる特徴を見やすい

中央値

定義 (中央値)

データを小さい順に

$$y_1 \leq y_2 \leq \cdots \leq y_n$$

と並べる。 $n = 2m - 1$ のとき

$$M_e = y_m,$$

$n = 2m$ のとき

$$M_e = \frac{y_m + y_{m+1}}{2}$$

を中央値（メディアン）という。

ポイント

中央値は、データを小さい順に並べたときの**中央の位置**を表す代表値である。

最頻値と最頻階級

定義 (最頻値・最頻階級・階級値)

- (1) 生データでは、最も多く現れる値を**最頻値**（モード）という。
- (2) データを階級にまとめた**度数分布表**では、最も度数が大きい階級を**最頻階級**という。
- (3) 階級 $[a, b)$ の中央の値

$$\frac{a + b}{2}$$

を**階級値**という。最頻階級の階級値を、**近似的な最頻値**として用いることがある。

例

最頻階級が 20 以上 30 未満なら、その階級値は

$$\frac{20 + 30}{2} = 25.$$

このとき、25 を近似的な最頻値として用いることがある。

調整平均

定義 (調整平均・トリム平均)

データを小さい順に

$$y_1 \leq y_2 \leq \cdots \leq y_n$$

と並べる。両端からそれぞれ k 個のデータを除いた平均

$$\bar{x}_{\text{trim}} = \frac{1}{n - 2k} \sum_{j=k+1}^{n-k} y_j$$

を調整平均 (トリム平均) という。

補足

極端に離れた値の影響を小さくしたい場合などに用いられる。

平均偏差と四分位偏差

定義 (平均偏差)

観測されたデータ $x_1, \dots, x_n$ の平均を $\bar{x}$ とする。

$$\frac{1}{n} \sum_{k=1}^n |x_k - \bar{x}|$$

をデータの平均偏差という。

定義 (四分位偏差)

第1四分位数を Q_1 、第3四分位数を Q_3 とするとき、

$$Q_D = \frac{Q_3 - Q_1}{2}$$

を四分位偏差という。

変動係数

定義 (変動係数)

観測されたデータの平均を $\bar{x} \neq 0$ 、標準偏差を s とする。

$$C_V = \frac{s}{|\bar{x}|}$$

をデータの**変動係数**という。

ポイント

変動係数は無次元であり、平均の大きさに対する相対的なばらつきを表す。

例

標準偏差がどちらも 1 mm でも、平均が 10 mm のデータと 100 mm のデータでは、平均に対する相対的なばらつきは異なる。